

Kajian Pustaka: Prediksi Spatiotemporal Multimodal Hotspot Kebakaran Gambut di Riau

Anonymous Author(s)

Affiliation

Address

email

Abstract

Kajian pustaka ini mensurvei literatur terkait prediksi kebakaran hutan dan lahan gambut menggunakan pendekatan deep learning spatiotemporal dan multimodal fusion. Kami mengidentifikasi tiga kesenjangan penelitian utama: (1) belum ada perbandingan sistematis antara pendekatan tabular dan spatiotemporal untuk prediksi hotspot kebakaran gambut di Indonesia, (2) fusi multimoda yang mengintegrasikan radar satelit, data cuaca, curah hujan, tutupan lahan, dan peta kerentanan gambut secara spatiotemporal belum pernah dilakukan, dan (3) analisis kontribusi relatif faktor lingkungan menggunakan explainable AI masih terbatas untuk konteks Indonesia.

1 Kajian Pustaka

1.1 Keterbatasan Deteksi Berbasis Satelit Optik dan Termal

Deteksi kebakaran gambut secara konvensional mengandalkan satelit polar seperti MODIS (Moderate Resolution Imaging Spectroradiometer) dan VIIRS (Visible Infrared Imaging Radiometer Suite) yang mendeteksi anomali termal pada permukaan bumi. Meskipun efektif untuk kebakaran permukaan yang besar, pendekatan ini memiliki tiga keterbatasan utama untuk konteks gambut.

Pertama, resolusi spasial MODIS sebesar 1 km per piksel terlalu kasar untuk mendeteksi kebakaran *smoldering* berskala kecil yang umum terjadi pada tahap awal kebakaran gambut [1]. Kedua, tutupan awan yang persisten di wilayah tropis, terutama pada musim kebakaran, menyebabkan banyak deteksi terlewatkan oleh satelit optik. Ketiga, api gambut yang membakar di bawah permukaan tanah memiliki suhu permukaan yang jauh lebih rendah dibanding api terbuka, sehingga sering berada di bawah ambang deteksi algoritma MODIS [2]. Pola hotspot temporal di Riau telah dipelajari oleh [3] yang mengidentifikasi korelasi antara sekuens hotspot dengan kondisi lahan gambut, namun penelitian tersebut belum mengintegrasikan data multimoda.

1.2 Pendekatan Deep Learning untuk Prediksi Kebakaran

Perkembangan deep learning telah membuka pendekatan baru untuk prediksi kebakaran yang tidak bergantung semata-mata pada deteksi anomali termal. Convolutional LSTM (ConvLSTM) yang diperkenalkan oleh [4] untuk prediksi curah hujan telah menjadi arsitektur dasar untuk berbagai tugas prediksi spatiotemporal, termasuk kebakaran hutan.

Beberapa penelitian terkini telah menunjukkan kinerja ConvLSTM yang menjanjikan untuk prediksi kebakaran. [5] mengembangkan model ConvLSTM dengan mekanisme attention untuk memprediksi penyebaran kebakaran hutan di Amerika Serikat, dan menunjukkan bahwa pendekatan deep learning spatiotemporal mengungguli model Auto-Regressive Moving Average (ARIMA) konvensional dengan margin yang signifikan. [6] mempercepat prediksi penyebaran api menggunakan Con-

vLSTM untuk panduan operasional, mencapai prediksi yang akurat dengan waktu komputasi yang jauh lebih rendah dibanding simulasi fisika.

Untuk konteks multimodal, [7] mengusulkan kerangka ensemble deep learning multimodal yang menggabungkan citra satelit, data topografi, dan meteorologi untuk prediksi kebakaran di Yunani dengan berbagai tingkat risiko dan mencapai akurasi yang kompetitif terhadap metode state-of-the-art. [8] mengembangkan kerangka deep learning spatiotemporal terpadu yang menggabungkan 3D CNN, LSTM, dan MLP untuk prediksi probabilistik kebakaran hutan di wilayah Mediterranean, mencapai AUC-ROC sebesar 0,962. Sementara itu, [9] mengembangkan sistem prediksi risiko kebakaran di Argentina menggunakan Dynamic World sebagai sumber tutupan lahan dan FIRMS sebagai label validasi, dan berhasil memenangkan NASA Space Apps Challenge 2025.

1.3 Multimodal Fusion untuk Prediksi Lingkungan

Fusi multimoda telah menjadi pendekatan yang semakin populer dalam prediksi fenomena lingkungan karena kemampuan untuk menangkap sinyal dari berbagai sumber fisik yang saling melengkapi. Untuk kebakaran gambut, fusi data radar, cuaca, curah hujan, dan tutupan lahan secara spatiotemporal belum banyak dieksplorasi dalam literatur.

Penelitian ini memanfaatkan Sentinel-1 SAR (Synthetic Aperture Radar) sebagai salah satu modalitas utama. Tidak seperti sensor optik, radar gelombang mikro dapat menembus awan dan memberikan informasi tentang kelembapan permukaan tanah secara langsung [10]. Hal ini sangat relevan untuk kebakaran gambut karena kelembapan tanah merupakan faktor penentu utama kerentanan kebakaran.

1.4 Kesenjangan Penelitian

Berdasarkan kajian pustaka di atas, beberapa kesenjangan penelitian dapat diidentifikasi. Pertama, belum ada penelitian yang secara sistematis membandingkan pendekatan tabular dan spatiotemporal untuk prediksi hotspot kebakaran gambut di Indonesia. Kedua, fusi multimoda untuk prediksi kebakaran gambut yang mengintegrasikan radar, cuaca, curah hujan, tutupan lahan, dan peta kerentanan gambut secara spatiotemporal belum pernah dilakukan. Ketiga, analisis kontribusi relatif faktor lingkungan terhadap risiko kebakaran gambut di Indonesia menggunakan metode explainable AI masih terbatas.

References

- [1] Dave van Wees, Guido R. van der Werf, James T. Randerson, Brendan M. Rogers, Yang Chen, Sander Veraverbeke, Louis Giglio, and Douglas C. Morton. Global biomass burning fuel consumption and emissions at 500 m spatial resolution based on the global fire emissions database (GFED). *Geoscientific Model Development*, 15(22):8411–8437, 2022.
- [2] Simon Whitburn, Martin Van Damme, Lieven Clarisse, Sophie Bauduin, Pierre-François Coheur, and Cathy Clerbaux. Doubling of annual ammonia emissions from the peat fires in indonesia during the 2015 El Niño. *Geophysical Research Letters*, 43(20), 2016.
- [3] Imas Sukaesih Sitanggang, Rizky Annisa, Lailan Syaufina, and Mega Anzani. Spatial pattern analysis of hot spot sequences in peatland area of Riau province. In *2018 3rd International Conference on Adaptive and Intelligent Agroindustry (ICAIA)*, 2018.
- [4] Xingjian Shi, Zhourong Chen, Hao Wang, Dit-Yan Yeung, Wai-Kin Wong, and Wang-chun Woo. Convolutional LSTM network: A machine learning approach for precipitation nowcasting. *Advances in Neural Information Processing Systems*, 28, 2015.
- [5] Arif Masrur, Manzhou Yu, Alexander Taylor, and Zhe Chen. Capturing wildfire spread dynamics: Attention-based spatiotemporal ConvLSTM for accurate prediction. *Ecological Informatics*, 81:102760, 2024.
- [6] Hamza Chakraa and Murat Bronz. Accelerating wildfire spread prediction for guidance: A ConvLSTM deep learning approach. In *AIAA SCITECH 2026 Forum*, 2026.
- [7] Ioannis Papakis, Grigorios Tsagkatakis, and Panagiotis Tsakalides. Multimodal ensemble deep learning for wildfire risk prediction in greece. *Remote Sensing*, 17(19):3310, 2025.

108 [8] Md. Abdullah Al Mamun. Unified spatiotemporal deep learning framework for probabilistic
109 wildfire ignition prediction. Technical report, 2026.
110
111 [9] Luciana Sinato and Carlos Rivas. Territorially-specialized machine learning for wildfire risk
112 assessment in argentina. 2026.
113 [10] Muh Taufik, Faiz Hasan, Evi Widyastuti, and Budi I. Setiawan. The impact of rewetting
114 peatland on fire hazard in riau, indonesia. *Sustainability*, 15(3):2169, 2023.
115
116
117
118
119
120
121
122
123
124
125
126
127
128
129
130
131
132
133
134
135
136
137
138
139
140
141
142
143
144
145
146
147
148
149
150
151
152
153
154
155
156
157
158
159
160
161